

분석 보고서

본 공모전은 국내외에 공개된 보건의료 빅데이터를 활용하여 데이터 분석 과정을 상세히 기술하고, 분석 결과를 재현 가능하도록 제시하여 빅데이터를 이용해서 분석하는 경험 공유하는 것을 목표로 합니다. 심사는 제출된 서류로만 진행되오니, 각 항목을 충실히 작성해주시기 바랍니다.

1. 제목			
국민건강영양조사 기반 남성 당뇨병 위험 예측 및 보험 언더라이팅 연계 : CatBoost와 리스크 스코어링			
2. 분석 주제			
로지스틱 회귀 분석 및 다양한 머신러닝 기법을 활용한 당뇨병 위험 요인 분석 및 예측 모델 개발과 보험 리스크 스코어링 활용			
참고 논문: Shinje Moon, Ji-Yong Jang, Yumin Kim, Chang-Myung Oh. (2021). Development and validation of a new diabetes index for the risk classification of present and new-onset diabetes:multicohort study. Scientific Reports, 11:15748, doi : 10.1038/s41598-021-95341-8			
데이터: 2019 - 2023년 국민건강영양조사(KNHANES), 남성			
3. 제출자 정보			
구분	성명	소속	직위
책임자	강민채	숙명여자대학교	학부생 4학년
공동연구자	김나원	숙명여자대학교	학부생 3학년
공동연구자	김서영	숙명여자대학교	학부생 3학년
1) 책임자 연락처 - 이메일 :alsco_hope@sookmyung.ac.kr - 전화번호(핸드폰) : 010-7713-1363			

4. 분석 데이터

1) 사용 데이터 : 국민건강영양조사 (KNHANES)

2) 자료가 일반인에게 공개되어 누구든지 얻을 수 있는 자료입니까?

- ☒ 일반 공개 (누구나 곧바로 다운로드 가능)
- ☐ 신청 필요 (가입 또는 신청 후 다운로드 가능)
- ☐ 허가 필요 (심사 및 허가 절차를 거쳐 다운로드 가능)
- ☐ 비공개

3) 데이터 출처 : 국민건강영양조사, 2013-2023. 질병관리청

<https://knhanes.kdca.go.kr/knhanes/archive/wsiNationHealthStatsPlus.do>

4) 데이터 특징 : 국민건강영양조사는 국가 단위 확률표본을 기반으로 한 보건 의료 빅데이터로 검진조사, 건강설문조사, 영양조사를 포함하여 국민의 건강 상태를 다차원적으로 파악할 수 있다. 대규모 변수와 연속적 조사 체계로 인해 다양한 연구와 정책적 활용이 가능하다.

5. 공모제출 분석 내용 (해당하는 내용 모두 선택)

1) 데이터 특성 및 전처리 과정의 문제점 해결.

- 본 연구에서는 자료의 특성을 반영하여 다음과 같은 전처리 과정을 수행하였다.
 1. 설문 미응답이나 검사 누락으로 발생하는 결측치는 수치형 변수는 중앙값, 범주형 변수는 최빈값으로 보정하고 임상적으로 불가능한 응답 코드(예: 88=무응답, 99=모름)는 모두 결측으로 처리하였다.
 2. 알코올 섭취량(alc_hol_g_per_week), 총콜레스테롤(chol), 백혈구 수(wbc) 등 극단값의 영향을 크게 받는 비대칭 분포 변수에는 log1p 변환을 적용하였다.
 3. 소득 및 교육변수는 원자료 내 여러 후보 변수를 자동으로 탐색하여 단일 변수(소득 4분위, 교육 수준)로 통합하였으며 BMI, 혈압, 혈당 변수는 임상 기준을 반영하여 각각 비만, 고혈압, 당뇨병 여부를 나타내는 이진 변수로 재구성하였다. 이를 통해 분석의 임상적 타당성을 확보하였다.
 4. 모델별 특성을 고려하여 전처리 과정은 차별적으로 적용하였다. 로지스틱 회귀는 변수 간 스케일 차이에 민감하므로 로그 변환과 표준화를 포함한 파이프라인을 적용하였다. 반면, 트리 기반 모델(RandomForest, XGBoost, CatBoost)은 스케일링을 생략하고

범주형 변수만 인코딩하여 학습에 활용하였다.

5. 변수 간 다중공선성 문제를 사전에 점검하였다. 예를 들어, BMI, 체중, 허리둘레와 같은 변수들은 높은 상관성을 보여 회귀계수 해석을 왜곡할 수 있었다. 이를 검증하기 위해 분산팽창지수(VIF, Variance Inflation Factor)를 산출하였고, VIF 값이 10 이상인 변수를 제거하거나 대체하였다.

- 최종적으로 본 연구의 전처리 과정은 (1) 결측치 및 이상치 처리, (2-3) 분포 안정화 및 임상 기준에 따른 파생 변수 생성, (4) 모델 특성에 따른 차별적 데이터 변환, (5) 다중공선성 조정을 통해 자료의 질을 높이고, 분석 결과가 임상적으로 타당하면서도 일반화할 수 있는 형태로 도출되도록 설계되었다.

☐ 데이터 수집, 저장, 불러오기

☒ 데이터 정제 (Data Cleaning)

☒ 데이터 변환 (Data Transformation)

☐ 데이터 병합 또는 분할

☐ 다른 데이터와의 연계

2) 데이터를 통한 새로운 인사이트 도출

- 전처리 후 정의된 20개 입력 변수에 대해 다양한 모델을 적용하여 당뇨병 발생의 주요 요인을 분석하였다. 로지스틱 회귀분석에서는 회귀계수를 기반으로 산출된 오즈비(Odds Ratio)를 통해 위험 요인과 보호 요인을 정량적으로 평가하였고, 트리 기반 모형(Random Forest, XGBoost, CatBoost)에서는 변수 중요도(feature importance)를 활용하여 예측 기여도를 검토하였다.
- 로지스틱 회귀 분석 결과, 공복혈당(num__glucose, OR=6.45), 연령(num__age, OR=2.42), 요당(num__glycosuria, OR=1.51), 허리둘레(num__waist, OR=1.41) 등이 당뇨병 발생 위험을 유의하게 증가시키는 요인으로 나타났다. 반면, 교육 수준(cat__education_4.0, OR=0.19; cat__education_3.0, OR=0.32)은 뚜렷한 보호 요인으로 확인되었으며, 수면

시간(num__sleep_hours, OR=0.85)과 헤모글로빈(num__hb, OR=0.80) 역시 위험을 감소시키는 방향으로 작용하였다. 이는 연령 및 복부 비만과 같은 전통적 위험 요인 외에도, 사회경제적 요인과 생활습관 요인(교육 수준, 수면 습관)이 당뇨병 발생에 독립적으로 기여함을 보여준다.

- 트리 기반 모형의 변수 중요도 분석에서도 유사한 경향성이 확인되었다. 네 가지 모형 모두에서 혈당, 연령, 허리둘레는 일관되게 상위 변수로 도출되었으며, 흡연량(pack_years), 헤모글로빈(hb), 혈압(sbp, dbp), 수면 시간(sleep_hours) 등도 주요 설명 변수로 나타났다. 반면, 고지혈증 여부(num__dyslip)나 심혈관질환 이력(num__cvd) 등 일부 임상 변수는 상대적으로 낮은 기여도를 보였다. 특히 교육 및 소득 변수는 로지스틱 회귀에서는 보호 요인으로서 뚜렷한 영향을 보였으나, 트리 기반 모형에서는 변수 중요도가 하위권에 분포하는 등 모형별 해석의 차이도 확인되었다. 이는 로지스틱 회귀가 변수 간 선형적 관계와 효과 크기를 정량적으로 보여주는 반면, 트리 기반 모형은 비선형적·상호작용적 패턴을 탐지하는 데 유리하기 때문으로 해석할 수 있다.

[] 새로운 시각화 생성

[✓] 새로운 분석 결과

3) 분석법 적용

- 본 연구에서는 보건의료 빅데이터를 기반으로 당뇨병 위험 예측 모델을 개발하기 위해, 로지스틱 회귀와 트리 기반 앙상블 모델을 중심으로 분석을 수행하였다. 분석 과정에서는 각 방법론의 장점을 살리면서 실제 데이터 분석에서 발생하는 문제를 해결하고자 하였다.
 1. 로지스틱 회귀를 적용하여 변수별 회귀 계수와 오즈비를 산출하였다. 이를 통해 개별 위험 요인의 방향성과 영향력을 직관적으로 해석할 수 있었다. 그러나 로지스틱 회귀는 비선형 관계나 변수 간 상호작용을 충분히 반영하지 못하는 한계가 있어, 예측 성능(Accuracy=0.848, F1=0.633) 측면에서는 트리 기반 모델 대비 다소 낮은 결과를 보였다.

2. 이를 보완하기 위해 트리 기반 앙상블 모델(Random Forest, XGBoost, CatBoost)을 적용하였다. Random Forest는 변수 간 상호작용을 포착하면서도 비교적 안정적인 성능(ROC-AUC=0.931, Accuracy=0.905, F1=0.713)을 나타냈으며, XGBoost와 CatBoost는 더 나은 ROC-AUC(각각 0.934, 0.933)와 Accuracy(0.934, 0.934)를 달성하였다. 특히, XGBoost와 CatBoost는 Class1(당뇨 환자군)에 대한 재현율(Recall)과 정밀도(Precision) 간 균형을 개선하여, 전체적으로 가장 높은 F1-score(약 0.742~0.743)를 기록하였다. 또한 Catboost는 범주형 변수 처리와 과적합 억제 측면에서 우수한 성능을 보였으며 ROC-AUC 평가에서 학습용 데이터와 검증용 데이터 모두에서 안정적인 결과를 도출하였다.

- 요약하면, 로지스틱 회귀는 해석 용이성 측면에서 강점을 지니는 반면, 트리 기반 앙상블 모델은 예측 성능과 변수 상호작용 반영에서 우수성을 보여주었다. 따라서 실제 보건의료 데이터 기반 당뇨병 예측에서는 로지스틱 회귀를 통한 위험 요인 탐색 + 트리 기반 모델을 통한 고성능 예측을 병행하는 것이 가장 효과적인 접근으로 판단된다.

☐ LLM을 이용한 분석

☒ 머신러닝을 이용한 분석

☐ 기타 (분석법 :)

4) 프로그램 개발

- 연속형 변수 간 상관관계 확인할 수 있는 히트맵을 구현하였다. 이를 통해 BMI, 체중, 허리둘레 간 강한 상관성을 확인하고 혈당 관련 변수와 생화학 지표 간의 연관성을 파악함으로써, 단순 통계 분석 결과를 보완하였다.

☐ 대시보드 프로그램 개발

☒ 탐색적 데이터 분석 (Exploratory Data Analysis – EDA)

☐ 리포트 작성 프로그램 개발

☐ 새로운 시각화 방법 개발

5) 기타

☐ 간단한 제목

해당 없음

6. 분석에 사용한 프로그램 (해당하는 내용 모두 선택)

1) 프로그램

☐ R

☒ Python

☒ Excel

☐ SQL

☐ SAS

☐ SPSS

☐ 기타 (프로그램명 :)

2) 프로그램 버전

python 3.12.11

3) 같이 사용한 주요 외부 라이브러리 또는 모듈

pandas : 2.2.2

numpy: 2.0.2

scikit-learn: 1.6.1

xgboost: 2.1.1

catboost: 1.2.7

lightgbm: 4.6.0

matplotlib: 3.10.0

seaborn: 0.13.2

scipy: 1.14.1

pyreadstat: 1.2.7

7. 소스코드 및 별첨 자료

1) 소스코드 제출 및 공개 여부

☐ 제출함. 공개 가능 ☒ 제출함. 평가에만 이용. 비공개 ☐ 미제출

2) 소스코드 링크 또는 첨부

(1) 데이터 로딩 (2019 - 2023 병합 + 남성 필터링)

```
import os, pandas as pd
def load_knhanes(data_dir):
    import pyreadstat
    frames=[]
    for y in range(2019, 2024):
        f=os.path.join(data_dir, f"HN{str(y)[-2:]}_ALL.sav")
        if not os.path.exists(f): continue
        df,_=pyreadstat.read_sav(f); df["YEAR"]=y; frames.append(df)
    if not frames: raise RuntimeError("No input files.")
    df=pd.concat(frames, ignore_index=True)
    return df[df["sex"]==1].copy()
```

(2) 파생변수 생성 - 핵심 변수군 (생활습관 지표, 신체 임상 지표, 혈액검사 지표, 사회경제 지표, 진단 여부 지표 / 그 외: 부록에 첨부)

```
import numpy as np, pandas as pd
# 1) 생활습관 지표
def calc_sleep(r):
    wk, we = r.get('BP16_1'), r.get('BP16_2')
    wk = np.nan if wk in [88,99] else wk
    we = np.nan if we in [88,99] else we
    try: return (float(wk)*5 + float(we)*2)/7
    except: return np.nan

def calc_alcohol(r):
    freq = {1:0, 2:0.06, 3:0.25, 4:0.75, 5:2.5, 6:5.5}.get(int(r.get('BD1_11',0)),0)
    cups = {1:1.5, 2:3.5, 3:5.5, 4:8, 5:10}.get(int(r.get('BD2_1',0)),0)
    return freq * cups * 10 # g/주

def smoking_status(row):
    if row.get('BS3_1') in [1,2]: return "current"
    if row.get('BS3_1') == 3: return "former"
    if row.get('BS1_1') == 3: return "never"
    return np.nan

def pack_years(row):
    if row['smoking']=="current" and pd.notna(row.get('BS2_1')) and
pd.notna(row.get('age')) and pd.notna(row.get('BS3_2')):
```

```

        return (row['BS3_2']/20) * (row['age'] - row['BS2_1'])
            if row['smoking']=="former" and pd.notna(row.get('BS6_2_1')) and
pd.notna(row.get('BS6_3')):
                return (row['BS6_3']/20) * row['BS6_2_1']
            if row['smoking']=="never": return 0
            return np.nan

# 2) 신체·임상 지표
def calc_bmi_cat(r):
    bmi = r.get('HE_BMI')
    if bmi is None or pd.isna(bmi):
        try: bmi = float(r.get('HE_wt')) / (float(r.get('HE_ht'))/100)**2
        except: return pd.NA
    return 1 if bmi<23 else (2 if bmi<25 else 3)

def calc_hypertension(df):
    sbp = pd.to_numeric(df.get("HE_SBP"), errors="coerce")
    dbp = pd.to_numeric(df.get("HE_DBP"), errors="coerce")
    med = pd.to_numeric(df.get("DI1_2"), errors="coerce")
    he_hp = pd.to_numeric(df.get("HE_HP"), errors="coerce")
    return ((sbp>=140)|(dbp>=90)|(med.isin([1,2,3,4,5]))|(he_hp==4)).astype(int)

# 3) 혈액검사 지표
# 총콜레스테롤, 중성지방, WBC, Hb, Cr → 단순 캐스팅
def cast_clinical(df):
    cast_map =
{"HE_chol": "chol", "HE_TG": "tg", "HE_WBC": "wbc", "HE_HB": "hb", "HE_crea": "crea"}
    for src, dst in cast_map.items():
        if src in df.columns:
            df[dst] = pd.to_numeric(df[src], errors="coerce")
    return df

# 4) 사회경제 지표
def create_edu(r):
    edu = r.get('educ')
    return np.nan if edu in [None, 8, 88, 99] else {3:1, 4:2, 5:3}.get(edu, 4)

def calc_income(row):
    for c in

```



```
[ 'incm', 'ho_incm', 'incm5', 'ho_incm5', 'incm_qurt', 'HINC_Q', 'INCOME' ]:
    if c in row.index:
        v = pd.to_numeric(row[c], errors='coerce')
        return v if v in [1,2,3,4] else np.nan
    return np.nan

# 5) 진단 여부 지표
def calc_dyslip(df):
    if 'DL1_dg' in df.columns: return (df['DL1_dg']==1).astype('Int64')
    return ((df.get('HE_HCHOL')==1)|(df.get('HE_HTG')==1)).astype('Int64')

def calc_cvd(row):
    ihd = any(row.get(c)==1 for c in ['HE_IHdfh1', 'HE_IHdfh2', 'HE_IHdfh3'] if c in row)
    st = any(row.get(c)==1 for c in ['HE_STRfh1', 'HE_STRfh2', 'HE_STRfh3'] if c in row)
    return int(ihd or st)

# 메인 엔지니어링 함수
def engineer_core(df):
    df["sleep_hours"] = df.apply(calc_sleep, axis=1)
    df["alcohol_g_per_week"] = df.apply(calc_alcohol, axis=1)
    df["smoking"] = df.apply(smoking_status, axis=1)
    df["pack_years"] = df.apply(pack_years, axis=1)
    df["bmi_cat"] = df.apply(calc_bmi_cat, axis=1)
    df["education"] = df.apply(create_edu, axis=1)
    df["income"] = df.apply(calc_income, axis=1)
    df["dyslip"] = calc_dyslip(df)
    df["hypertension"] = calc_hypertension(df)
    df["cvd"] = df.apply(calc_cvd, axis=1)
    df = cast_clinical(df)
    return df
```

(3) 라벨 정의(당뇨 0/1)

```
def label_diabetes(df):
    gl = pd.to_numeric(df.get("glucose"), errors="coerce")
    a1c = pd.to_numeric(df.get("HE_HbA1c"), errors="coerce") if "HE_HbA1c" in
df.columns else None
    diag = [c for c in ['HE_DM', 'HE_DMdg', 'DM1_dg', 'DM2_dg', 'DM3_dg', 'DM4_dg', 'DM8_dg']
if c in df]
```

```
trt = [c for c in ['HE_DMdr', 'HE_insulin'] if c in df]
diagnosed = df[diag].eq(1).any(axis=1) if diag else pd.Series(False,
index=df.index)
treated = df[trt].eq(1).any(axis=1) if trt else pd.Series(False, index=df.index)
lab = (gl>=126) if gl is not None else False
if a1c is not None: lab = lab | (a1c>=6.5)
return (diagnosed | treated | lab).astype(int)
```

(4) 전처리 + 프로토타입 모델(CatBoost)

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
from sklearn.pipeline import Pipeline
from catboost import CatBoostClassifier

def build_cat_pipeline(X):
    cat_cols = [c for c in ["income", "education"] if c in X.columns]
    num_cols = [c for c in X.columns if c not in cat_cols]
    pre = ColumnTransformer([
        ("num", "passthrough", num_cols),
        ("cat", OneHotEncoder(drop="first", handle_unknown="ignore"), cat_cols)
    ], remainder="drop")
    model = CatBoostClassifier(iterations=500, learning_rate=0.05, depth=6,
                               eval_metric="AUC", random_seed=42, verbose=False)
    return Pipeline([("pre", pre), ("model", model)])
```

(5) 확률보정 + 점수(PDO) + 밴딩

```
import numpy as np, pandas as pd
from sklearn.calibration import CalibratedClassifierCV
from sklearn.metrics import roc_auc_score, brier_score_loss

def prob_to_score(p, BASE=600, PDO=20, p0=1/51):
    p=np.clip(p,1e-6,1-1e-6)
    factor = -PDO/np.log(2); offset = BASE - factor*np.log(p0/(1-p0))
    return np.round(offset + factor*np.log(p/(1-p))).astype(int)

def map_band(s):
    return "S" if s>=720 else ("A" if s>=680 else ("B" if s>=640 else ("C" if s>=600
```

```

else "D"))))

def calibrate_and_score(best_pipeline, X_tr, y_tr, X_te, y_te):
    cal = CalibratedClassifierCV(best_pipeline, method="isotonic", cv=3).fit(X_tr,
y_tr)
    p_tr = cal.predict_proba(X_tr)[:,-1]; p_te = cal.predict_proba(X_te)[:,-1]
    auc_te = roc_auc_score(y_te, p_te); brier_te = brier_score_loss(y_te, p_te)
    score = prob_to_score(p_te); band = pd.Series(score).apply(map_band)
    return {"p_te":p_te, "AUC":auc_te, "Brier":brier_te, "score":score, "band":band}

```

(6) 실행 스니펫(누수 제거 포함- glucose, glycosuria 제외)

```

from sklearn.model_selection import train_test_split

SELECT = [
    "age", "income", "education", "pack_years", "alcohol_g_per_week", "sleep_hours",
    "bmi_cat", "waist", "sbp", "dbp",
    "chol", "tg", "wbc", "hb", "crea",
    "dyslip", "cvd", "hypertension",
    "glycosuria", "glucose"]

def run_minimal(data_dir):
    df = load_knhanes(data_dir)
    df = engineer_core(df)
    y = label_diabetes(df)
    X = df[[c for c in SELECT if c in df.columns]].copy()

    # 정보누수 제거
    for leak in ["glucose", "glycosuria"]:
        if leak in X.columns:
            X.drop(columns=[leak], inplace=True)

    X_tr, X_te, y_tr, y_te = train_test_split(
        X, y, test_size=0.3, stratify=y, random_state=42
    )
    pipe = build_cat_pipeline(X_tr)
    pipe.fit(X_tr, y_tr)

    out = calibrate_and_score(pipe, X_tr, y_tr, X_te, y_te)

```

return out

3) 별첨 자료명

해당 없음

8. 요약

1) 데이터 전처리 및 파생변수 생성

- 2019-2023 국민건강영양조사(KNHANES) 중 남성 데이터를 추출
- Moon et al.(2021)에서 제시한 주요 당뇨 위험 변수(연령, 소득, 교육, 흡연 등)를 KNHANES 변수와 매핑
- 공복 혈당 및 요당 등 누수 변수는 제외하여 장기 위험 예측 모델에 적합화 진행

2) 프로토타입 모델구현

- CatBoost Classifier를 기반으로 학습/검증 데이터 분한 후 예측 모델 개발
- RandomizedSearchCV로 최적의 하이퍼파라미터 탐색
- Isotonic Calibration 적용으로 예측 확률 보정 후 AUC와 Brier score로 성능 평가

3) 성능 확장 및 리스크 스코어링

- 예측 확률을 PDO(Points to Double the Odds) 방식으로 점수화 진행
- 점수를 기준으로 S/A/B/C/D 밴드로 계층화
- 밴드별 평균 점수 및 실제 발생률을 산출하여 위험도 차별화

4) 보험과의 연계

- 요율산식 : $Premium_b = Base\ Premium \times p^{-b} \times CapRule(0.85 \sim 1.25)$ (밴드 평균 위험률 ÷ 전체 평균 위험률)
- 인수 정책: S; 보험료할인, A; 표준 인수, B,C; 보험료 할증, D; 조건부 인수 및 거절

9. 본문

(0) 데이터 범위 선정 : 2019 -2023년 사용

본 연구에서는 선행연구에서 사용한 2013 - 2018년 데이터와, 최근의 위험 요인을 더 잘 반영할 수 있는 2019 - 2023년 데이터 중 어느 범위를 활용할지 사전에 검토하였다. 이를 위해 남성 집단을 대상으로 임상, 생활습관, 혈액검사, 진단 지표를 공통으로 정리한 뒤, 두 시기 간 변수 분포의 차이를 통계적으로 비교하였다. 연속형 변수는 **Welch t-test**, 범주형 변수는 카이제곱 검정을 실시하였으며, 다중 검정에 따른 유의수준 왜곡을 보정하기 위해 유의수준 5%의 **bonferroni** 보정을 적용하였다.

그 결과, 연령, 수면시간, 허리둘레, 크레아티닌, 혈압 등 여러 연속형 변수와 요당, 이상지질혈증, **BMI** 범주와 같은 일부 범주형 변수에서 시기별로 유의한 차이가 존재하는 것으로 확인되었다. 반면 공복혈당, 총콜레스테롤, 주당 음주량 등 일부 변수에서는 두 시기 간 차이가 없었다. 하지만 전체적으로는 차이가 유의한 변수의 수가 더 많이 확인되었기 때문에 최근 자료가 과거와 다른 특성을 갖고 있음을 보여준다.

따라서 본 연구에서는 현재의 위험 구조를 더 잘 반영할 수 있도록 2019 - 2023년 데이터만을 최종 분석에 사용하였다.

(1) 데이터 전처리 및 변수 구성 과정

모델링에 사용한 주요 변수는 참고논문에서 제시한 약 40개의 당뇨병 위험 예측 후보 변수 중 유의한 위험 요인을 선별하였다. 논문에서 제시한 대표적인 위험 요인은 아래와 같다.

- 인구사회학적 변수: 연령, 교육 수준, 소득 사분위
- 생활습관 변수: 음주량, 흡연, 수면시간
- 임상 변수: **BMI**, 허리둘레 수축기 이완기 혈압
- 생화학적 변수: 총콜레스테롤, 중성지방, 백혈구수, 헤모글로빈, 크레아티닌
- 진단 여부 변수: 고혈압, 이상지질혈증, 심혈관질환, 당뇨 진단 및 치료 여부, 요당

본 연구 역시 이와 유사한 변수 체계를 반영하여 데이터 전처리를 수행하였다. 특히, 논문에서 강조된 연령, 허리둘레, 혈압, 혈액 검사 지표, 생활습관 요인을 중심으로 변수를 구성하였다. 이후 일부 변수는 실제 데이터 상황에 맞추어 파생변수로 재정의하였다.

- 수면시간 (**sleep_hours**)
 - 원자료의 주중 수면시간(**BP16_1**)과 주말 수면시간(**BP16_2**)을 이용
 - 비유효 코드(88=무응답, 99=결측)는 **NA** 처리 후, 주중×5일 + 주말×2일을 평균하여 1일

수면시간(시간 단위)으로 산출

- 음주량 (alcohol_g_per_week)
 - 음주 빈도(BD1_11)를 주당 횟수로 환산
1회 음주량(BD2_1)을 표준화된 잔 수로 변환: 1=1.5잔, 2=3.5잔, ..., 5=10잔 이상
 - 표준잔당 알코올 10g 기준으로 주당 총 섭취 g 산출
- 흡연 관련 변수
 - 흡연 상태(smoking): 현재 흡연(current), 과거 흡연(former), 비흡연(never)으로 구분
 - Pack-years (pack_years): (일일 흡연량/20) × 흡연 기간(년)
 - 현재 흡연자는 (현재 나이 - 시작 연령) 활용,
 - 과거 흡연자는 금연 시점까지의 총 흡연기간 반영
- BMI 범주 (bmi_cat)
 - BMI < 23: 정상(1), 23-25: 과체중(2), ≥25: 비만(3)
 - 원자료의 BMI(HE_BMI)가 없을 경우, 키(HE_ht)와 체중(HE_wt)으로 계산
- 교육 수준 (education)
 - 원자료(educ)를 네 단계로 단순화. (초졸 이하, 중졸, 고졸, 대졸 이상)
 - 비유효 코드(8, 88, 99)는 NA 처리
- 소득 사분위 (income)
 - 소득 관련 여러 후보 변수(incm, incm5, ho_incm 등) 중 실제 존재하는 컬럼 선택
 - 1~4 사분위만 인정, 이외 값은 NA 처리
- 이상지질혈증 (dyslip)
 - 진단 변수(DL1_dg)가 있으면 해당 값 사용
 - 없을 경우 고콜레스테롤(HE_HCHOL) 또는 고중성지방(HE_HTG) 여부를 종합하여 산출
- 고혈압 (hypertension)
 - 수축기 혈압(SBP ≥ 140) 또는 이완기 혈압(DBP ≥ 90), 또는 고혈압 약물 복용·진단 이력 존재
시 1로 정의
- 심혈관질환 병력 (cvd)

- 허혈성 심장질환, 뇌졸중 가족력 관련 항목 중 하나라도 1일 경우 1로 정의

(2) 프로토타입 모델 구현 및 성능

프로토타입 단계에서는 임상·생활습관·혈액검사 지표 등 총 20개 변수('age', 'income', 'education', 'pack_years', 'alcohol_g_per_week', 'waist', 'sbp', 'dbp', 'chol', 'tg', 'wbc', 'hb', 'crea', 'dyslip', 'sleep_hours', 'bmi_cat', 'cvd', 'hypertension', 'glycosuria', 'glucose')로 예측 입력을 구성하였고, 당뇨병 진단 여부 라벨(diabetes_label)을 목표변수로 설정하였다.

모델의 일반화 성능을 가늠하기 위해 층화 분할(stratified split)로 학습하였으며, 검증 데이터 비율은 7:3으로 구성하였다. 트리 기반 전처리기를 적용하여 수치형 변수는 별도의 스케일링 없이 전달하고, 명목형 변수는 원-핫 인코딩으로 변환 하였다. 그리고 공복 혈당(glucose) 및 요당(glycosuria)은 진단에 직접적으로 연동이 되는 변수이기 때문에, 예측 시점 정보 가정에 따라 정보 누수의 가능성이 존재한다. 이에 따라서 프로토타입 구현 이후의 리스크 스코어링 단계에서 '포함 모델' 과 '제외 모델'을 분리해 비교하였다.

모델링은 전처리기와 catboost 분류기를 단일 파이프라인으로 결합해 학습과 예측 과정에서 일관된 데이터 처리 절차를 적용시켰다. CatBoost 모델은 반복 횟수(iteration)=500, 트리 깊이(depth)=6, 성능 지표 = AUC 기준 최적화로 적용했으며, 실험 재현성을 위해 랜덤 시드(seed)= 42로 고정하였다.

성능 평가는 확률 기반 성능(ROC-AUC)과 클래스 예측 정확도(F1, Accuracy, 리포트)를 산출하였다. 그 결과, 기본 CatBoost 모델은 ROC-AUC : 0.8869, Accuracy : 0.8895, F1-score : 0.7322로 확인되었다. 이는 당뇨병 여부 예측이 가능함을 보여주며, 이후 하이퍼파라미터 최적화 및 확률 보정 과정을 통해서 추가적인 성능 향상을 도모하였다.

(3) 모델 성능 향상 - 최적의 하이퍼 파라미터 탐색

프로토타입 모델 이후, 일반화 성능을 높이기 위해서 RandomizedSearchCV(n_iter=20, 3겹 교차검증, ROC-AUC 기준)를 활용해서 하이퍼파라미터 탐색을 수행하였다. 그 결과, 최적화된 CatBoost모형은 테스트 데이터에서 ROC-AUC : 0.9330, Accuracy : 0.9341, F1-score : 0.7430을 달성하였다. 이는 기본 설정 대비 성능이 향상되었다는 점을 보여준다.

추가적으로 CatBoost 모형에 Isotonic calibration을 적용하여 예측 확률을 보정하였다. 보정된 모형의 성능은 AUC (train/test) : 0.9534 / 0.9325, Brier score ((train/test) : 0.0478 / 0.053)으로 나타났다. 이는 해당 모형이

당뇨병 유무를 구별하는 능력이 매우 우수하며, 산출된 예측 확률 자체도 실제 발생 확률에 매우 근접함을 의미한다. 따라서 본 연구에서는 보정된 CatBoost 모델을 최종 예측 모델로 결정하였다.

(4) 리스크 스코어링 및 언더라이팅 적용 가능성

본 연구에서는 PDO 방식(Points to Double the Odds)을 적용하여 위험 점수를 계산하였다. 이 방식은 점수가 일정 간격만큼 오르면 odds 가 두 배 변하도록 점수를 설계하는 방식으로, 보험 언더라이팅 분야에서 거의 표준으로 사용된다. 이 방식을 이용하여 누수변수(glucose, glycosuria)를 포함한 경우와 제외한 경우를 구분하여 Score scaling을 각각 진행하였다.

기준 확률과 오즈 배율을 기반으로 점수를 계산해 확률이 감소할수록 점수가 선형적으로 상승하도록 설계하였다. 이 점수를 기준으로 'S' (720점 이상) / 'A' (680점 이상) / 'B' (640점 이상) / 'C' (600점 이상) / 'D' (600점 미만) 총 5개의 그룹으로 나누어 각 그룹의 인원 수, 위험률, 평균 점수를 산출하였다. 이때 요율 가중치(premium factor)는 수동 매핑 방식으로 각 그룹에 다음과 같이 부여하였다.

S 그룹	A 그룹	B 그룹	C 그룹	D 그룹
0.95 (5% 할인)	1.00 (표준 요율)	1.05 (5% 할증)	1.10 (10% 할증)	np.nan (인수 심사 보류)

[표1] 각 그룹별 요율 가중치

누수변수(glucose, glycosuria)를 포함한 모델에서는 아래의 [표2]와 같이 S/B/C그룹은 위험률이 거의 0%에 수렴하는 반면, D그룹의 평균 위험률은 25%로 상대적으로 매우 높았다. 이는 누수변수의 영향으로, 모델이 향후 발생 위험을 예측하기보다는, 현재 당뇨병 상태와 강하게 연관된 변수를 반영했기 때문으로 해석할 수 있다. 즉 이 모델은 '진단 및 현재 당뇨 탐지용(의료 스크리닝, 질병관리)'에 가까운 모델로 해석할 수 있다.

반대로 아래의 [표3]과 같이 누수변수를 제외한 경우 S그룹의 인원은 868명에서 627명으로 감소하였지만 D그룹의 인원은 3014명에서 3319명으로 증가하였다. D그룹의 위험률이 25.8%에서 23.1%로 약간 완화된 것으로 보아, 명확한 당뇨 확진자뿐 아니라 간접적인 위험 요인(비만, 혈압, 생활습관 등)만으로 장기적 고위험군을 더 넓게 D그룹으로 분류하게 된다는 것을 알 수 있다. 즉 누수변수(glucose, glycosuria)를 제외한 모델은 보험 언더라이팅 및 리스크 기반 요율 산정 목적에 더 적합하다는 결론을 도출할 수 있다.

Band	n	mean_p	mean_score	premium_factor
S	868	0.0000	886.0000	0.95
A	0	-	-	-
B	339	0.0039	647.5487	1.05
C	651	0.0121	615.1997	1.10
D	3014	0.2579	484.6553	NaN

[표2] Band summary - 누수 변수 포함

Band	n	mean_p	mean_score	premium_factor
S	627	0.0000	886.0000	0.95
A	0	-	-	-
B	229	0.0039	647.9214	1.05
C	697	0.0088	625.6571	1.10
D	3319	0.2311	529.5972	NaN

[표3] Band summary - 누수 변수 제외

(5) 보험과의 연계

위의 과정을 통해 도출된 리스크 점수는 보험 요율 산식에 연계하여 적용 가능성을 검토하였다. 원칙적으로는 다음 [수식 1]과 같이 밴드별 위험률 대비 전체 위험률을 반영하여 요율을 산출할 수 있다.

$$Premium_b = Base\ Premium \times \frac{\bar{p}}{\bar{p}_b} \times CapRule(0.85 \sim 1.25)$$

[수식 1] 요율 산식

하지만, 본 연구 데이터의 구조적 제약으로 인해 자동 산식 적용 시 왜곡이 발생한다. 그 결과 실험에서는 수동

매핑 방식을 적용하였다. 이에 따라 S 그룹은 5% 할인, A 그룹은 표준 요율, B/C 그룹은 각각 5%, 10% 할증을 적용하였다. D 그룹은 인수심사 보류 대상으로 설정하였으며, 보험 언더라이팅과 연계 시 조건부 인수 또는 건강 프로그램 참여 시 재검토가 가능하도록 설계하였다. 이를 통해 제안된 리스크 점수가 실제 보험 요율 산정과 인수정책 수립에 실질적으로 활용될 수 있음을 확인하였다.

(6) 시사점 및 한계

리스크 스코어링 결과는 단순히 예측 성능을 평가하는 것 뿐만 아니라, 보험 언더라이팅 및 요율 산정에 실무적으로 적용될 수 있다는 점에서 의미가 있다. 밴드별 요율 가중치를 부여하여 낮은 저위험군의 집단에는 보험료 할인 혜택을, 고위험군의 집단에는 형평성있는 할증을 적용함으로써, 보험사의 리스크 관리와 소비자의 건강 관리 동기를 동시에 충족할 수 있다. 특히 D 그룹을 조건부 인수로 설정하고 건강 프로그램 참여 시 재검토하는 구조는 단순한 보험가입의 거절이 아닌 행동 개선을 유도하는 실질적 수단이 될 수 있다. 즉 단순한 리스크 선별을 넘어 예방 차원의 건강 관리를 유도할 수 있다.

또한 공공 보건 데이터인 KNHANES를 활용하여 리스크 기반 보험 설계의 가능성을 제시하였기에, 민간 보험사뿐 아니라 국가 차원의 건강보험 및 예방 정책에도 시사점을 제공한다. 다만 자동 요율 산식 적용에는 데이터 구조적 제약으로 인한 한계가 있었으며, 실제 상품화 과정에서는 감독당국의 가이드라인 내에서 전문가 조정이 필수적이다. 또한 데이터가 단일시점(2019-2023)에 국한되어있기 때문에 장기 추적 자료와 다양한 위험요인의 검토가 필요하다. 이는 향후 후속 연구에서 보완해야 할 과제로 남아있다.